

GABRIELA MANGILI SIMÕES
RAYSSA GOMIDES MARCONATO

RELATÓRIO TÉCNICO

Pipeline de Inteligência Esportiva para Apoio à Convocação

Mineração de Dados | Copa do Mundo FIFA 2026

Sumário

Sumário Executivo3

 Principais Achados3

1. Construção da Base de Dados3

2. Pré-processamento e Análise Exploratória4

3. Clusterização: Perfis de Jogadores7

4. Classificação: Nível Copa9

5. Recomendação Estratégica10

Limitações e Próximos Passos10

Conclusão11

Checklist de Aderência ao Enunciado11

Sumário Executivo

Este relatório consolida um pipeline de mineração de dados aplicado ao contexto de convocação para a Copa do Mundo de 2026. A análise integra estatísticas esportivas do FBref com valores de mercado do Transfermarkt, identifica perfis táticos por clusterização e treina modelos supervisionados para classificar jogadores em nível competitivo.

Os resultados indicam quatro perfis principais de atletas: atacantes de alta produção, defensores, goleiros e jogadores de apoio/equilibrados. Na classificação, os modelos apresentaram desempenho elevado e equilibrado, com F1-Score próximo de 0,94. A recomendação final prioriza um elenco balanceado, combinando especialização tática, regularidade competitiva e oportunidades de custo-benefício.

Indicador	Resultado
Base final	2.925 jogadores
Transfermarkt	196 jogadores com valor de mercado
Cobertura do merge	6,70%
Modelos supervisionados	Regressão Logística e Random Forest
Clusterização	K-Means com K=4

Principais Achados

- A base final possui 2.925 jogadores, com cobertura de mercado de 6,70% após o merge.
- A distribuição de valor de mercado é assimétrica, com poucos atletas extremamente valorizados e maioria fora do topo do mercado.
- A clusterização com K=4 separa perfis interpretáveis e úteis para composição de elenco.
- A Regressão Logística apresentou leve vantagem nas métricas médias, enquanto o Random Forest contribuiu para interpretar a importância das features.
- O falso negativo é o erro mais sensível para a federação, pois pode excluir jogadores competitivos da lista ampliada de observação.

1. Construção da Base de Dados

A base foi construída a partir do FBref, que fornece estatísticas esportivas de jogadores, e do Transfermarkt, utilizado para enriquecer a análise com valor de mercado. Como as fontes não compartilham identificador único, a integração foi realizada por nomes normalizados. Essa normalização remove acentos, padroniza letras minúsculas e reduz espaços extras.

Fonte / etapa	Quantidade	Observação
FBref original	2.953	Base estatística com ligas Big5 e Brasileiro
FBref após remoção de duplicidades	2.925	Mantido um registro por jogador, ano de nascimento e clube
Transfermarkt raspado	200	Top jogadores por valor de mercado
Com valor após merge	196	Cobertura parcial esperada
Sem valor após merge	2.729	Jogadores fora do top raspado ou sem correspondência

Cobertura do merge FBref + Transfermarkt




Figura 1 - Cobertura do merge entre FBref e Transfermarkt.

A baixa cobertura do merge não representa falha do pipeline; ela reflete a diferença de escopo entre as fontes. O Transfermarkt raspado cobre apenas jogadores altamente valorizados, enquanto o FBref inclui uma população muito mais ampla.

2. Pré-processamento e Análise Exploratória

No pré-processamento, as posições foram simplificadas para GK, DF, MF e FW. Campos posicionais ausentes foram preenchidos com zero, pois ausência de xG para goleiros ou ausência de defesas para atacantes representa uma característica da função, não perda de informação. As variáveis numéricas foram convertidas para tipos adequados e normalizadas antes da modelagem.




Figura 2 - Distribuição do valor de mercado com linha de mediana.

A distribuição mostra concentração de jogadores em faixas menores de valor e poucos atletas com valores muito elevados. Para uma federação, isso reforça que a construção de elenco não deve depender apenas de estrelas caras.




Figura 3 - Perfil médio por posição.

O perfil por posição evidencia papéis distintos: atacantes concentram produção ofensiva, defensores têm maior volume de ações defensivas e meio-campistas apresentam contribuição mais distribuída.



Figura 4 - Nacionalidades com maior valor médio de mercado.




Figura 5 - Relação entre idade e valor de mercado.

A relação entre idade e valor de mercado ajuda a observar o ciclo de valorização dos atletas. Em geral, jogadores próximos ao pico competitivo concentram maior valor, enquanto atletas mais jovens podem representar potencial futuro e atletas mais experientes exigem avaliação de custo-benefício.




Figura 6 - Relação entre xG e gols.

A relação positiva entre xG e gols confirma que volume e qualidade de chances são bons indicadores de produção ofensiva. Jogadores acima da tendência podem indicar eficiência de finalização; abaixo dela, possível problema de conversão.

3. Clusterização: Perfis de Jogadores

A clusterização foi realizada com K-Means após normalização das features. O número de clusters foi avaliado pelo Método do Cotovelo e pelo Silhouette Score. Embora K=3 apresente bom desempenho quantitativo, K=4 foi mantido pela melhor interpretação esportiva, alinhada aos principais perfis do futebol.




Figura 7 - Método do Cotovelo para escolha de K.




Figura 8 - Silhouette Score por número de clusters.




Figura 9 - Projeção PCA dos clusters.

Cluster	Nome	Gols	Assist.	xG	Desarmes	Intercep.	Defesas
0	Atacantes	7,56	3,34	7,37	13,23	8,69	0,00
1	Apoio / Equilibrados	0,76	0,56	0,82	6,16	4,76	0,78
2	Defensores	1,36	1,69	1,42	26,04	24,67	0,00
3	Goleiros	0,00	0,13	0,01	0,43	0,35	77,02

A presença de clusters mistos é analiticamente relevante: o algoritmo não apenas reproduz posições oficiais, mas identifica similaridade de comportamento estatístico. Isso ajuda a detectar jogadores versáteis ou perfis de apoio.

4. Classificação: Nível Copa

O target foi definido pela mediana de minutos jogados (1.041). Jogadores acima da mediana foram classificados como Titular Regular / Nível Copa; os demais como Rotação/Reserva. Para evitar data leakage, foram removidas as variáveis minutos, 90s, Starts e valor_mercado das features do classificador.

Classe	Interpretação	Quantidade
0	Rotação/Reserva	1.463
1	Titular Regular / Nível Copa	1.462

Modelo	Accuracy	Precision	Recall	F1-Score
Regressão Logística	0,939	0,944	0,934	0,939
Random Forest	0,933	0,933	0,933	0,933

Matrizes de confusão




Figura 10 - Matrizes de confusão dos modelos supervisionados.




Figura 11 - Importância das features no Random Forest.

A Regressão Logística apresentou leve vantagem consolidada, com métricas próximas de 0,94. O Random Forest ficou muito próximo e foi usado para interpretar as variáveis mais influentes. As principais features indicam que regularidade de jogos, ações defensivas e produção ofensiva são determinantes para classificar jogadores em nível competitivo.

Em uma lista ampliada de convocação, o falso negativo é mais grave: deixar de identificar um jogador realmente competitivo reduz opções estratégicas. O falso positivo ainda pode ser filtrado por análise de vídeo, observação tática e avaliação médica.

5. Recomendação Estratégica

A recomendação é montar o elenco equilibrando quatro perfis: atacantes de produção ofensiva, defensores com alto volume de desarmes/interceptações, goleiros especialistas e jogadores de apoio/equilibrados. Essa combinação reduz dependência de atletas muito caros e amplia a robustez do elenco para diferentes cenários de jogo.

Jogador	Clube	Pos.	Min.	Produção	xG	Valor
Vedat Muriqi	Mallorca	FW	2.948	22 gols / 1 ast.	18,5	Não disponível
Deniz Undav	Stuttgart	FW	2.151	19 gols / 6 ast.	16,4	Não disponível
Esteban Lepaul	Rennes	FW	2.421	19 gols / 5 ast.	15,7	Não disponível
Ante Budimir	Osasuna	FW	2.758	17 gols / 0 ast.	17,1	Não disponível
Patrik Schick	Leverkusen	FW	1.898	16 gols / 3 ast.	17,2	Não disponível
Joaquin Panichelli	Strasbourg	FW	2.193	16 gols / 1 ast.	14,2	Não disponível

Os nomes acima devem ser tratados como candidatos para scouting aprofundado, não como convocação automática. A leitura correta é: o modelo ajuda a priorizar observação, reduzindo o universo de jogadores para uma análise técnica mais detalhada.

Limitações e Próximos Passos

Limitação	Impacto	Melhoria recomendada
Merge por nome	Pode gerar ambiguidade em jogadores homônimos	Usar identificadores únicos, clube, idade e nacionalidade no matching

Target baseado em minutos	Minutos refletem uso, mas não capturam todo o mérito técnico	Combinar minutos com rating, convocatórias reais e avaliação de scouts
Dados agregados	Perdem contexto de adversário, fase do jogo e função tática	Incorporar dados evento a evento e tracking
Ausência de contexto físico/médico	Não mede risco de lesão, fadiga ou disponibilidade	Adicionar relatórios médicos e métricas físicas

Conclusão

O pipeline desenvolvido cumpre as etapas centrais de um projeto de mineração de dados: coleta, integração, limpeza, exploração, clusterização, classificação e recomendação. A análise mostra que dados estatísticos podem apoiar a montagem de elenco ao identificar perfis complementares, jogadores subobservados e critérios objetivos para priorização de scouting.

Para uso profissional, o modelo deve ser entendido como ferramenta de apoio à decisão. A decisão final de convocação precisa integrar dados, vídeo, contexto tático, condição física, avaliação médica e julgamento da comissão técnica.

Checklist de Aderência ao Enunciado

Requisito	Status
Merge FBref + Transfermarkt documentado	Atendido
Cobertura percentual do merge	Atendido
5+ visualizações com interpretação	Atendido
Cotovelo, Silhouette, PCA e clusters nomeados	Atendido
Classificação com 2 modelos e StratifiedKfold	Atendido
Accuracy, Precision, Recall, F1 e Matriz de Confusão	Atendido
Importância de features e discussão FP/FN	Atendido
Recomendação estratégica com jogadores reais	Atendido
Limitações do trabalho	Atendido